

RELATÓRIO DE ACOMPANHAMENTO

Disciplina: Dissertação de Mestrado

1. Identificação

Aluno	Nycolas W. Da Silva Santos
Orientador	Prof. Xexéo
Programa	Pós-Graduação em Sistemas e Computação (PGSC) — IME
Área de Concentração	Ciência da Computação
Título Provisório	Atribuição de Algoritmos de Criptografia Leve em Cenário Ciphertext-Only via Aprendizado de Máquina

2. Introdução

Este relatório descreve a trajetória completa das atividades de pesquisa desenvolvidas até o momento na dissertação de mestrado, cujo objetivo é investigar se algoritmos de criptografia leve (LWC) padronizados pelo NIST, especificamente Ascon-AEAD128 e GIFT-COFB, podem ser distinguidos a partir exclusivamente de seus criptogramas, sem acesso à chave ou ao texto em claro, por meio de técnicas de aprendizado de máquina.

As atividades realizadas incluem: (i) implementação e validação de wrappers criptográficos de referência para os dois algoritmos; (ii) construção de um pipeline de geração de datasets com protocolo rigoroso de key-holdout; (iii) extração de 307 características estatísticas dos criptogramas e implementação de um pipeline de seleção em três estágios; (iv) condução de experimentos de classificação com múltiplos modelos (Random Forest, SVM, XGBoost e CNN 1D); (v) implementação de controles positivos para validar a capacidade do pipeline de detectar sinais estruturais quando presentes; e (vi) redação e finalização de um artigo científico submetido ao SBSeg 2026, que constitui um recorte desta investigação.

O resultado central obtido até o momento é a confirmação da hipótese nula (H_0): sob protocolo experimental rigoroso, nenhum dos modelos avaliados foi capaz de distinguir criptogramas de Ascon-AEAD128 e GIFT-COFB com desempenho estatisticamente superior ao acaso. Esse achado é consistente com as garantias teóricas de segurança esperadas para esquemas AEAD modernos.

Encontram-se atualmente em desenvolvimento extensões metodológicas baseadas em redes neurais convolucionais, descritas na Seção 4 deste relatório.

Nota: Foi utilizado Inteligência Artificial Generativa (Chat GPT) como ferramenta de apoio na redação deste relatório.

3. Atividades Realizadas

3.1 Implementação da infraestrutura criptográfica de referência

Foram implementados wrappers em Python, via CFFI (C Foreign Function Interface) no modo API out-of-line, para as implementações de referência em C do Ascon-AEAD128 e do GIFT-COFB. Essa abordagem permite invocar diretamente as funções de cifragem e decifragem sem o overhead de gerenciamento de processos externos, ao mesmo tempo em que preserva integralmente o código de referência oficial, sem qualquer modificação.

A corretude de ambas as implementações foi validada por meio dos vetores de teste oficiais (Known Answer Tests — KATs) distribuídos pelo NIST. Os 1.089 vetores de teste do Ascon-AEAD128 (arquivo LWC_AEAD_KAT_128_128.txt) e os 1.089 vetores do GIFT-COFB (arquivo LWC_AEAD_KAT_GIFTCOFB128_128.txt) foram validados com sucesso em sua totalidade, com tempo de execução inferior a 10 milissegundos. Para fins de rastreabilidade, o hash SHA-256 de cada binário compilado é registrado automaticamente nos metadados de cada dataset gerado.

3.2 Geração e validação do dataset experimental

Foi desenvolvido um pipeline de geração de dados que utiliza plaintexts extraídos do Standardized Project Gutenberg Corpus (SPGC). Cada amostra de plaintext possui tamanho fixo de 64 KB (65.536 bytes). O pipeline está especificado para gerar aproximadamente 60.000 criptogramas, distribuídos entre os dois algoritmos avaliados (Ascon-AEAD128 e GIFT-COFB), a partir de 300 chaves distintas, com 100 amostras por chave por algoritmo.

A política de geração adotada inclui: nonces implementados como contador global de 128 bits, garantindo unicidade por construção; e uso das mesmas chaves e dos mesmos plaintexts para os dois algoritmos avaliados, eliminando variáveis de confusão entre as classes.

O protocolo de validação adotado combina key-holdout, no qual as chaves do conjunto de teste (20% do total) nunca aparecem no conjunto de treinamento, com validação cruzada de 5 folds, estratificada por chave, aplicada dentro da partição de treinamento e validação (80% do total). Essa combinação previne que os modelos aprendam padrões específicos de uma chave em vez de assinaturas genuínas do algoritmo.

O pipeline de geração inclui cinco verificações de integridade aplicadas a cada dataset produzido: estrutura, unicidade de nonces, uniformidade de bytes (teste χ^2), compressibilidade e verificação de decifragem ponta a ponta (decrypt spot-check).

3.3 Extração e seleção de características estatísticas

Foi implementado um extrator que computa 307 características estatísticas de cada criptograma, organizadas em seis famílias: histograma de bytes (256 características), entropia de Shannon e estatística qui-quadrado (4), agregados de n-gramas de bytes (15), autocorrelação e testes de runs (18), complexidade de Lempel-Ziv e razões de compressão (4), e características espectrais via Transformada Discreta de Fourier (10).

Para reduzir a dimensionalidade e evitar vazamento de informação do conjunto de teste, foi implementado um pipeline de seleção de características em três estágios, limiar de variância combinado com informação mútua, mRMR (minimum Redundancy Maximum Relevance) e Boruta, aplicado exclusivamente à partição de treinamento de cada fold de validação.

3.4 Modelagem e avaliação experimental

Foram avaliados quatro classificadores: Random Forest, SVM com kernel RBF, XGBoost e uma rede neural convolucional unidimensional (CNN 1D) operando diretamente sobre as sequências de bytes dos criptogramas, sem características artesanais. A avaliação seguiu protocolo estatístico rigoroso, incluindo F1-macro como métrica principal, intervalos de confiança via bootstrap (1.000 reamostragens) e teste de McNemar para comparações pareadas entre modelos, com correção de Bonferroni.

Nos experimentos de classificação conduzidos, nenhum modelo atingiu desempenho estatisticamente superior ao acaso (F1-macro $\approx 0,50$) na tarefa de distinguir Ascon-

AEAD128 de GIFT-COFB, com intervalos de confiança bootstrap consistentemente cobrindo o valor de referência do acaso.

3.5 Controles positivos e análise de robustez

Para verificar que a ausência de sinal não decorria de falha do pipeline experimental, foram conduzidos dois controles positivos utilizando Vigenere como classe adicional.

3.6 Produção científica: artigo submetido ao SBSeg 2026

Os resultados descritos nas seções 3.1 a 3.5 foram consolidados em um artigo científico, intitulado “Ciphertext-Only Classification of Lightweight AEAD Algorithms Using Machine Learning”, submetido ao Simpósio Brasileiro de Cibersegurança (SBSeg 2026). O artigo constitui um recorte da investigação mais ampla conduzida na dissertação, com foco específico no par Ascon-AEAD128 / GIFT-COFB sob o protocolo experimental vigente até aquele momento.

4. Atividades em Andamento

Além da infraestrutura descrita na Seção 3, encontram-se em desenvolvimento as seguintes extensões metodológicas.

4.1 Extração de características via redes neurais convolucionais

Está em desenvolvimento uma extensão da estratégia de extração de características, na qual redes neurais convolucionais são empregadas não apenas como classificadores fim-a-fim, mas como extratoras de representações latentes a serem combinadas com as características estatísticas clássicas. Especificamente, encontram-se em implementação:

- CNN unidimensional (CNN 1D), operando sobre a sequência de bytes do criptograma, da qual se extrai o vetor latente da penúltima camada (antes da camada de classificação) como representação aprendida;
- CNN bidimensional (CNN 2D), na qual o criptograma é reorganizado como uma imagem em escala de cinza, processada por camadas convolucionais 2D, da qual também se extrai um vetor latente;
- Estratégia híbrida, que concatena as 307 características estatísticas clássicas aos vetores latentes extraídos pelas duas arquiteturas convolucionais, alimentando um classificador tradicional (Random Forest ou XGBoost) com a representação combinada.

Essa frente de trabalho amplia a pergunta de pesquisa original: além de avaliar se características estatísticas conhecidas permitem distinguir os algoritmos, investiga-se também se representações aprendidas automaticamente — isoladamente ou em combinação com as características clássicas — revelam algum sinal não capturado pela abordagem puramente estatística.

4.2 Considerações de infraestrutura computacional

Dado o aumento substancial no tamanho dos criptogramas (de até 1.040 bytes para 65.552 bytes por amostra), foi necessário revisar os parâmetros de treinamento das redes convolucionais para viabilizar a execução.

5. Próximas Etapas

- Execução em larga escala da geração do dataset (60.000 amostras) e validação de integridade;
- Execução do pipeline de extração das 307 características clássicas sobre o novo dataset;
- Implementação e treinamento das arquiteturas CNN 1D e CNN 2D como extratoras de características;
- Implementação do classificador híbrido (características clássicas + representações latentes);
- Implementação do controle positivo com cifra de Vigenère;
- Execução do protocolo completo de validação cruzada (5 folds) e key-holdout (80/20) sobre os quatro caminhos experimentais (clássico, CNN 1D, CNN 2D e híbrido);
- Análise comparativa entre os quatro caminhos por meio de teste de McNemar pareado;
- Redação dos capítulos da dissertação relativos à geração de dados, extração de características, metodologia experimental, resultados, discussão e conclusão.

6. Considerações Finais

As atividades realizadas até o momento estabeleceram uma infraestrutura experimental sólida e validada, wrappers criptográficos conformes às especificações do NIST, pipeline de geração de dados reproduzível, extração de características estatísticas consolidada e protocolo de avaliação estatisticamente rigoroso. O resultado obtido (H_0 não rejeitada) já foi consolidado em artigo submetido ao SBSeg 2026.

A incorporação de representações aprendidas por redes convolucionais busca fortalecer a robustez das conclusões da dissertação e ampliar sua contribuição metodológica para a área de criptoanálise assistida por aprendizado de máquina.

8. Assinaturas

Nycolas W. Da Silva Santos — Aluno

Prof. Jose Antonio Moreira Xéxeo

Rio de Janeiro, 19 de junho de 2026.